


ANÁLISIS TRANSCRIPTÓMICO DE LA RESPUESTA A CR(VI) EN KLEBSIELLA SP. AQSCR


BIOPYTHON

ZYANYA, YEIMI Y MARINA

25/11/2025



LA AMENAZA DEL CR(VI)



Cr(VI)



Cr(III)

- ANIÓN SOLUBLE (CrO_4^{2-} , HCrO_4^-)
- SE MUEVE EN AGUAS SUBTERRÁNEAS
- CANCERÍGENO Y MUTAGÉNICO
- BIOACUMULABLE
- CATIÓN INSOLUBLE (Cr^{3+} , $\text{Cr}(\text{OH})_3$)
- NUTRIENTE → ESENCIAL EN METABOLISMO
- PRECIPITA EN SUELOS

PROBLEMA AMBIENTAL:


- CR(VI) = CONTAMINANTE TÓXICO, CANCERÍGENO
- ALTA MOVILIDAD EN ACUÍFEROS
- TRATAMIENTOS FÍSICO-QUÍMICOS COSTOSOS




SOLUCIÓN BIOTECNOLÓGICA:

- BACTERIAS REDUCTORAS DE CR(VI) → CR(III)
- KLEBSIELLA SP. AQSCR: AISLADA DE ACUÍFERO CONTAMINADO
- RESISTENTE A 34 MM CR(VI)

KLEBSIELLA SP. STRAIN AQSCR



**AISLADO DE AGUA SUBTERRÁNEA
CONTAMINADA CON CROMATO**



- **255 GENES ↑ REGULADOS**
- **240 GENES ↓ REGULADOS**
- **MÚLTIPLES VÍAS ACTUANDO EN CONJUNTO**
- **ESTRATEGIA INTEGRADA DE SUPERVIVENCIA**

1. Resistencia EXTREMA = 34 mM Cr(VI)

2. pH ÓPTIMO ALCALINO = 8-9 (condiciones naturales del acuífero)

3. INDEPENDIENTE de bombas de expulsión (chrA)

4. ADAPTACIÓN RÁPIDA = fase de retraso más corta

OBJETIVOS DEL PROYECTO

- 1. Implementar un pipeline reproducible de análisis de RNA-seq**
- 2. Identificar genes diferencialmente expresados bajo estrés por Cr(VI)**
- 3. Caracterizar los mecanismos de adaptación molecular**
- 4. Validar hallazgos del artículo original mediante análisis computacional**

FLUJO COMPLETO DEL ANÁLISIS:

CATEGORÍA	HERRAMIENTA	PROPÓSITO	
DESCARGA	SRA TOOLKIT	OBTENCIÓN DE DATOS PÚBLICOS	HTTPS://GITHUB.COM/ZYANYAALD/TRANSCRIPTOME-ANALYSIS-KLEBSIELLA-/TREE/MAIN/DOCS Notas Pipeline Workflow BLOQUE 0 — Descarga automatizada de datos y genoma de referencia 0.1 Pipeline_2.0.py (pipeline maestro: descarga SRA + genoma) Rol en el pipeline Este es el primer script que se debe ejecutar en un proyecto nuevo. Está diseñado para ser totalmente reproducible y automatizar todo el proceso de: • encontrar todos los SRR del BioProject, • descargarlos, • convertirlos a FASTQ, • encontrar y descargar automáticamente el mejor genoma de referencia desde NCBI Assembly.
QC	FASTQC / MULTIQC	CONTROL CALIDAD	
PREPROCESAMIENTO	TRIMMOMATIC	RECORTE DE ADAPTADORES	
ALINEAMIENTO	BOWTIE2	MAPEO VS GENOMA DE REFERENCIA	
CONTEO	FEATURECOUNTS	CONTEO POR GEN	
ESTADÍSTICA	PYDESEQ2	EXPRESIÓN DIFERENCIAL	
VISUALIZACIÓN	MATPLOTLIB / SEABORN	GRAFICAS PROFESIONALES	



BLOQUE 0 — DESCARGA AUTOMATIZADA DE DATOS → PIPELINE_2.0.PY → DESCARGA_GENOMA_REFERENCIA.PY

“AUTOMATIZAR LA OBTENCIÓN DE DATOS PÚBLICOS Y GARANTIZAR REPRODUCIBILIDAD TOTAL”

- ENCONTRAR TODOS LOS SRR DEL BIOPROJECT
- DESCARGARLOS
- CONVERTIRLOS A FASTQ
- ENCONTRAR Y DESCARGAR AUTOMÁTICAMENTE EL MEJOR GENOMA DE REFERENCIA DESDE NCBI ASSEMBLY.

```
# 1. BÚSQUEDA AUTOMÁTICA
Entrez.esearch("SRP291413") → ['SRR12998916', 'SRR12998917', ...]

# 2. DESCARGA INTELIGENTE SRA
prefetch SRRxxxxxx → raw_sra/ # Evita redescargas
fasterq-dump → fastq/         # Conversión a FASTQ pareado

# 3. SELECCIÓN DEL MEJOR GENOMA
fetch_reference_package() → Encuentra genoma óptimo en NCBI

# 4. VALIDACIÓN INTEGRIDAD
Verificación MD5 + Descompresión automática
```

```
python descarga_genoma_referencia.py \
-q "Klebsiella sp. AQSCr" \
-s AQSCr \
-o genome/
```



```
data/
├─ fastq/           # 12 FASTQ (6 muestras × 2)
├─ genome/          # Genoma referencia + anotaciones
└─ raw_sra/         # Datos SRA originales
```


BLOQUE 1 - CONTROL DE CALIDAD DE LECTURAS CRUDAS

RUN_QC_RAW.SH



EVALÚA LA CALIDAD DE LAS LECTURAS CRUDAS ANTES DE CUALQUIER RECORTE, GENERA REPORTES POR MUESTRA FASTQC Y UN RESUMEN CONJUNTO MULTIQC.

```
# 1. EVALUACIÓN INDIVIDUAL
fastqc → Reportes por muestra

# 2. RESUMEN GLOBAL
multiqc → Dashboard unificado

# COMANDO EJECUTADO:
bash src/run_qc_raw.sh
```



```
data/qc/
├── SRR12998916_1_fastqc.html    # Reporte individual
├── SRR12998916_2_fastqc.html
├── ...
└── multiqc_report.html        # 📊 Resumen visual global
```

BLOQUE 2 – LIMPIEZA Y PREPARACIÓN DE LECTURAS

RUN_TRIMMOMATIC.SH → ELIMINAR SECUENCIAS DE BAJA CALIDAD Y ADAPTADORES QUE AFECTAN EL ANÁLISIS

```
#!/bin/bash

# === Simple Trimmomatic batch script ===
# Klebsiella_AqSCr_RNAseq project
# Author: Marina Mendoza

IN="data/fastq"
OUT="data/trimmed"
ADAPT="data/trimmomatic/TruSeq3-PE.fa"

mkdir -p "$OUT"

for r1 in "$IN"/*.1.fastq; do
    base=$(basename "${r1%.1.fastq}")
    r2="$IN/${base}_2.fastq"

    echo "Trimming $base..."

    trimmomatic PE -threads 8 \
        "$r1" "$r2" \
        "$OUT/${base}_1.trimmed.fastq" "$OUT/${base}_1.unpaired.fastq" \
        "$OUT/${base}_2.trimmed.fastq" "$OUT/${base}_2.unpaired.fastq" \
        ILLUMINACLIP:"$ADAPT":2:30:10 \
        LEADING:3 TRAILING:3 SLIDINGWINDOW:4:20 MINLEN:50
done

echo "Done! Trimmed files saved in $OUT"
```



```
data/trimmed/
├─ SRR12998916_1.trimmed.fastq
├─ SRR12998916_2.trimmed.fastq
├─ SRR12998916_1.unpaired.fastq
└─ SRR12998916_2.unpaired.fastq
```

VERIFICACIÓN POST-LIMPIEZA

RUN_QC_TRIMMED.SH →

REPITE EL QC PERO AHORA SOBRE LOS FASTQ YA RECORTADOS

```
#!/bin/bash

# === QC for trimmed FASTQ files ===
# Klebsiella_AqSCr_RNAseq project
# Author: Marina Mendoza

IN="data/trimmed"
OUT="data/qc_trimmed"

mkdir -p "$OUT"

echo "Running FastQC on trimmed reads..."
fastqc -t 8 -o "$OUT" "$IN"/*.trimmed.fastq

echo "Summarizing with MultiQC..."
conda activate multiqc
multiqc "$OUT" -o "$OUT"


echo "Done! Reports in: $OUT"
```



```
data/qc_trimmed/
├─ SRR12998916_1.trimmed_fastqc.html
├─ multiqc_report.html          # 📄 Comparativa visual
└─ multiqc_data/                # 📁 Datos procesados
```


BLOQUE 3 — ALINEAMIENTO Y MÉTRICAS DE MAPEO

RESUMEN VISUAL



SCRIPTS

RUN_INDEX_GENOME.SH

RUN_BOWTIE2.SH


RUN_FLAGSTAT.SH

BLOQUE 4 — CONTEO DE LECTURAS POR GEN

RUN_FEATURECOUNTS.SH

SORTED BAM + GFF —► FEATURECOUNTS —► COUNTS_FINAL.TXT

PREPARE_DEA_INPUTS.PY



BLOQUE 5 — ANÁLISIS DE EXPRESIÓN DIFERENCIAL (DEA) + VISUALIZACIONES


RUN_PYDESEQ2.PY



IMPLEMENTA UN ANÁLISIS TIPO DESEQ2 EN PYTHON, CALCULA: NORMALIZACIÓN POR TAMAÑO DE BIBLIOTECA, DISPERSIÓN, TEST DE WALD, P-VALORES Y PADJ, CONTEOS NORMALIZADOS. RESUME RESULTADOS Y GENERA ARCHIVOS PARA PLOTS POSTERIORES.


PLOT_VOLCANO.PY

REPRESENTA VISUALMENTE: - EN X LOG2FOLDCHANGE, - EN Y LOG10(PADJ)
PERMITE VER: GENES CON CAMBIOS GRANDES FC ALTO), GENES CON ALTA SIGNIFICANCIA (PADJ BAJO), SEPARACIÓN ENTRE SOBRERREGULADOS Y SUBREGULADOS.




VISUALIZA LOS PATRONES DE EXPRESIÓN DE LOS GENES MÁS SIGNIFICATIVOS. PERMITE VER CLUSTERS DE GENES, Y CÓMO SE AGRUPAN LAS MUESTRAS POR CONDICIÓN.


PLOT_HEATMAP_TOP_GENES.PY



BLOQUE 6 —VISUALIZACION DE LOS DATOS CON SEABORN

seabornpipeline.py







BLOQUE 6 — ANÁLISIS EXPLORATORIO (EDA)

PLOT_EDA_BASIC.PY →

TOMA LOS BAM ALINEADOS Y EL ARCHIVO GFF DE ANOTACIÓN,
CUENTA CUÁNTAS LECTURAS CAEN EN CADA CDS / GEN,
PRODUCE LA TABLA DE CONTEOS BRUTOS POR GEN Y POR
MUESTRA.



BLOQUE 7: ANOTACIÓN FUNCIONAL

PYTHON SRC/RUN_KEGG_ENRICHMENT_IMPROVED.PY	→	• IDENTIFICA PATHWAYS SIGNIFICATIVOS
PYTHON SRC/RUN_FUNCTIONAL_ANNOTATION.PY	→	• ANOTACIÓN FUNCIONAL COMPLETA DE GENES
PYTHON SRC/RUN_COG_ANALYSIS.PY	→	• ANÁLISIS COG (CLUSTERS OF ORTHOLOGOUS GROUPS)
PYTHON SRC/RUN_PCA_ANALYSIS.PY	→	• ANÁLISIS DE COMPONENTES PRINCIPALES
PYTHON SRC/RUN_CLUSTERING_ANALYSIS.PY	→	• CLUSTERING JERÁRQUICO DE MUESTRAS
PYTHON SRC/RUN_DENSITY_PLOTS.PY	→	• GRÁFICAS DE DENSIDAD DE EXPRESIONES
PYTHON SRC/RUN_EGGNOG_FROM_PROTEINS.PY	→	• ANOTACIÓN CON EGGNOG-MAPPER

RESULTADOS CLAVE OBTENIDOS:

--- PATHWAYS MÁS ENRIQUECIDOS (UP-REGULADOS):

BASE EXCISION REPAIR (SCORE: 3.19) - 72 GENES ↑

OXIDATIVE PHOSPHORYLATION (SCORE: 2.80) - 99 GENES ↑

TWO-COMPONENT SYSTEM (SCORE: 2.79) - 83 GENES ↑

BIOSYNTHESIS OF UNSATURATED FATTY ACIDS (SCORE: 1.48) - 23 GENES ↑

AMINO SUGAR METABOLISM (SCORE: 1.47) - 19 GENES ↑

--- RESPUESTA FUNCIONAL A CR(VI):

ESTRÉS OXIDATIVO: 100% UP-REGULADO (99 GENES)

REPARACIÓN DNA: 100% UP-REGULADO (72 GENES)

SEÑALIZACIÓN: 100% UP-REGULADO (83 GENES)

METABOLISMO ÁCIDOS GRASOS: 100% UP-REGULADO (23 GENES)

METABOLISMO ENERGÉTICO: 100% DOWN-REGULADO (187 GENES)




GHOS TKOALA

- **Reconstrucción de rutas:** Los KO IDs permiten usar KEGG Mapper para visualizar qué rutas metabólicas están presentes en tu conjunto de datos.
- **Taxonomía:** Además de funciones, GhostKOALA puede dar pistas sobre la clasificación taxonómica de las secuencias
- **Asigna K numbers (KO IDs):** Cada secuencia de aminoácidos que subes en formato FASTA se compara contra bases de datos de referencia (procariontes, eucariontes y virus)
- **Clasificación funcional:** Una vez anotadas, las secuencias se agrupan en categorías como metabolismo de carbohidratos, lípidos, aminoácidos, procesos celulares, etc..



ANOTACION FUNCIONAL

- LpxA, LpxB, LpxD (lipid A biosynthesis): esenciales para la síntesis de lipopolisacárido (LPS), factor de virulencia.
- dnaE (DNA pol III): replicación del ADN.
- accA (acetyl-CoA carboxylase): metabolismo de lípidos.
- gspK (secretion system): relacionado con sistemas de secreción bacteriana.
- metN/metI/metQ (methionine transport): transportadores de aminoácidos.



- **Transportadores de aminoácidos/metales (metN, metI, metQ – K02071/72/73)**

Los ABC transporters son conocidos por participar en resistencia a metales pesados.

- **Proteínas de membrana externa (hlpA/ompH – K06142; bamA/SAM50 – K07277)**

En bacterias Gram negativas, las porinas regulan la entrada de aniones como Cr(VI).

- **Proteínas de respuesta al estrés oxidativo (yaeR – K08234, glyoxylase I family protein),**

Cr(VI) genera especies reactivas de oxígeno (ROS).

Enzimas como glyoxylasas ayudan a neutralizar el daño oxidativo, aumentando la tolerancia.

- **ClcA/ClcB (K03281 – chloride channel protein, ClC family)**

Son canales de membrana que ayudan a mantener el equilibrio iónico.

Pueden participar en la entrada/salida de aniones como cromato (CrO_4^{2-}), modulando la toxicidad.

- **cutF/nlpE (K06079 – copper homeostasis protein)**

Relacionado con homeostasis de cobre.

Los sistemas de homeostasis de metales suelen tener funciones cruzadas en resistencia a otros metales pesados, incluyendo Cr(VI).


RELACIONADOS

A CRVI



Taxonomy data [Preview first 1000](#) | [Download](#)

Taxonomic
category




 Bacteria Enterobacteria
 Undef

La mayoría de las secuencias se clasifican como Klebsiella (Enterobacteria) → consistente con el organismo de estudio. Algunas secuencias aparecen como Escherichia, Pectobacterium, Nostoc o incluso virus → esto refleja homología conservada en la base de datos, no necesariamente que la muestra esté contaminada.

KEGG MAPPER

CATIONIC ANTIMICROBIAL PEPTIDE (CAMP) RESISTANCE



qué tipos de proteínas y cómo se agrupan funcionalmente.

- **Nivel General**
 - KEGG Orthology (KO)
 - 39 de tus secuencias tienen asignado un KO ID.
- **Familias de Proteínas: Metabolismo**
 - Enzimas
 - 21 proteínas anotadas como enzimas.
 - **Proteínas de Biosíntesis de Lipopolisacáridos**
 - 4 proteínas relacionadas con la síntesis de LPS, un factor de virulencia clave en Klebsiella.
 - **Proteínas de Síntesis y Degradación de Peptidoglicano**
 - 1 proteína involucrada en la síntesis o degradación de peptidoglicano.
 - **Enzimas Relacionadas con Aminoácidos**
 - enzimas relacionadas con el metabolismo de aminoácidos.

KEGG Mapper Reconstruction Result

Pathway (35)

Brite (20)

Brite Table (4)

Show matched objects

Genes and Proteins

Orthologs and modules

[ko00001 KEGG Orthology \(KO\) \(39\)](#)

Protein families: metabolism

[ko01000 Enzymes \(21\)](#)

[ko01001 Protein kinases \(1\)](#)

[ko01002 Peptidases and inhibitors \(2\)](#)

[ko01005 Lipopolysaccharide biosynthesis proteins \(4\)](#)

[ko01011 Peptidoglycan biosynthesis and degradation proteins \(1\)](#)

[ko01004 Lipid biosynthesis proteins \(1\)](#)

[ko01006 Prenyltransferases \(1\)](#)

[ko01007 Amino acid related enzymes \(2\)](#)

Protein families: genetic information processing

[ko03000 Transcription factors \(1\)](#)

[ko03021 Transcription machinery \(1\)](#)

[ko03011 Ribosome \(1\)](#)

[ko03016 Transfer RNA biogenesis \(4\)](#)

[ko03012 Translation factors \(3\)](#)

[ko03032 DNA replication proteins \(2\)](#)

[ko03400 DNA repair and recombination proteins \(1\)](#)

[ko03029 Mitochondrial biogenesis \(2\)](#)

Protein families: signaling and cellular processes

[ko02000 Transporters \(5\)](#)

[ko02044 Secretion system \(1\)](#)

[ko02022 Two-component system \(1\)](#)

VENTAJAS	DESVENTAJAS
Rapidez y escalabilidad: Capaz de manejar hasta 500,000 secuencias en un solo trabajo (hasta 300 MB).	Dependencia de KEGG: Solo asigna funciones basadas en lo que está en KEGG; si tu organismo o proteína no tiene representación, la anotación puede ser incompleta.
Cobertura amplia: Incluye referencias de eucariontes, procariontes y virus, lo que lo hace útil para metagenómica.	Menor sensibilidad que BLASTp: Aunque más rápido, el algoritmo GHOSTX puede perder alineaciones más finas que BLASTKOALA.
Integración directa con KEGG: Los resultados se enlazan con rutas metabólicas y bases de datos KEGG, facilitando análisis posteriores.	Limitaciones de formato: Solo acepta secuencias de aminoácidos en FASTA, no ADN directamente.
Accesibilidad: Es gratuito y en línea, sin necesidad de instalar software pesado.	Resultados generales: La anotación es funcional y taxonómica, pero no ofrece predicciones estructurales ni detalles experimentales.

GRACIASSS